

Muddiest Points III

Frage: *Ich bin nun zwar in der Lage, in einem Project zu arbeiten. Aber was das genau ist und was genau alles in ein Project gehört habe ich irgendwie immer noch nicht ganz verstanden. Können wir das nochmals kurz anschauen?*

Antwort: Ein **R-Projekt** ist eine klar abgegrenzte Arbeitsumgebung in RStudio. Du kannst es dir wie einen gemeinsamen Rahmen für alles vorstellen, was zu einer bestimmten Analyse, Übung, Seminararbeit oder Forschungsarbeit gehört. In ein R-Projekt gehört grundsätzlich alles, was notwendig ist, um eine Analyse nachvollziehbar durchzuführen: also z.B. Daten, Code, Ergebnisse, Berichte und weitere relevante Materialien.

Technisch erkennst du ein R-Projekt an einer Datei mit der Endung `.Rproj`. In unserem Fall ist das die Datei `ryouready.Rproj`. Diese Datei liegt auf der obersten Ebene unseres Projektordners. Wenn du diese Datei öffnest, öffnest du nicht einfach nur eine einzelne Datei, sondern das gesamte Projekt in RStudio. RStudio weiss dann, dass dieser Ordner der zentrale Ausgangspunkt für unsere Arbeit ist.

Wenn ein R-Projekt geöffnet wird, setzt RStudio automatisch das **Working Directory** auf den Ordner, in dem die `.Rproj`-Datei liegt. Das Working Directory ist der Ort, von dem aus R nach Dateien sucht und an dem R neue Dateien speichert, wenn kein anderer Speicherort angegeben wird.

In unserem Projekt ist also der Ordner mit der Datei `ryouready.Rproj` der zentrale Projektordner. Alle Unterordner wie `code`, `data`, `methods`, `preregistration` und `reports` sind Teil dieses Projekts. Sie enthalten unterschiedliche Bestandteile der Arbeit, gehören aber logisch zur gleichen Analyseumgebung.

Der wichtigste Vorteil eines R-Projekts ist, dass die Analyse einen festen Ausgangspunkt bekommt. Dadurch ist klar geregelt, wo die Dateien und der Code liegen, wo Ergebnisse gespeichert werden und welche Dateien überhaupt zur Analyse gehören. Das macht die Arbeit deutlich übersichtlicher. Gerade wenn ein Projekt über mehrere Wochen oder Monate läuft, ist es sonst schnell schwierig nachzuvollziehen, welche Datei wofür verwendet wurde.

Ein weiterer grosser Vorteil ist, dass R-Projekte das Arbeiten mit **relativen Pfaden** ermöglichen. Ein relativer Pfad beschreibt den Weg zu einer Datei immer ausgehend vom Projektordner. Dadurch musst du keine absoluten Pfade verwenden, die nur auf deinem eigenen Computer funktionieren. Stattdessen kann sich der Code auf die Struktur innerhalb des Projekts beziehen.

Das macht den Code stabiler und übertragbarer. Wenn eine andere Person denselben Projektordner öffnet und die Struktur gleichbleibt, kann derselbe relative Pfad innerhalb der Projektstruktur verwendet werden. Dadurch wird die Analyse besser reproduzierbar.

Frage: *Ich habe leider nicht ganz verstanden, wie konkret wir jetzt den Datenanalyseplan anpassen müssen, damit dieser zu unserer Abgabe passt, bzw. was genau wir da machen müssen. Dasselbe trifft auf das Codebook zu. Auch hier bin ich mir sehr unsicher, wie dieses jetzt strukturiert werden soll, dass dieses zur Abgabe passt.*

Antwort: Die Unsicherheit ist nachvollziehbar, da du Datenanalyseplan und Codebook ursprünglich für die **Originaldaten der Studie von Grinschgl et al. (2021)** erstellt hast. Für die Abschlussabgabe arbeitest du nun aber mit deinen **individuellen simulierten Rohdatensätzen**.

Wichtig ist: du musst den Datenanalyseplan nicht komplett neu schreiben! Die inhaltliche Grundlage bleibt weiterhin die Originalstudie und an den Hypothesen sowie geplanten Analysen hat sich nichts verändert! Was sich geändert hat, ist die **konkrete Datengrundlage**. Deshalb musst du deinen Datenanalyseplan überall dort anpassen, wo die bisherige Formulierung noch von den Originaldaten ausgeht oder nicht mehr zu deinen simulierten Daten passt.

Der Datenanalyseplan soll am Ende konsistent zur tatsächlichen Abgabe passen. Das bedeutet: Er soll nachvollziehbar beschreiben, mit welcher Datengrundlage du arbeitest, wie du mit dieser Datengrundlage umgehst und welche Analyseschritte du darauf anwenden willst. Besonders sorgfältig prüfen solltest du daher alle Abschnitte, die sich direkt auf die Daten beziehen, insbesondere **data access**, **data collection procedures**, **missing data**, **data exclusion** und **data identifiers**.

Für das **Codebook** gilt dieselbe Grundidee: Es soll die Daten beschrieben, mit denen du in der Abschlussabgabe tatsächlich arbeitest. Wenn die simulierten Datensätze dieselben Variablen und dieselben Variablennamen enthalten wie die Originaldaten, müssen nur wenige Dinge angepasst werden. Wenn sich aber Variablennamen, Formate oder der Umgang mit fehlenden Werten unterscheiden, muss das Codebook entsprechend aktualisiert werden.

Das Codebook soll also nicht einfach die Originaldaten dokumentieren, sondern deine aktuelle Datengrundlage. Eine andere Person sollte daraus nachvollziehen können, welche Variablen in deinen Datensätzen vorkommen, was diese Variablen bedeuten, wie sie codiert sind und wie sie in deiner Analyse verwendet werden.

- ➔ Du verwendest also Datenanalyseplan und Codebook aus dem Semester als Grundlage, passt die aber an die simulierten Daten an. Der Datenanalyseplan beschreibt das geplante analytische Vorgehen auf Basis der neuen Datengrundlage. Das Codebook beschreibt die Variablen dieser neuen Datengrundlage. Beide Dokumente sollten am Ende konsistent mit deinen R-Skripten und deiner Abschlussabgabe sein.

Frage: *Ich bin mir bei der finalen Abgabe nicht sicher, wie der vorprozessierte Datensatz ganz genau aussehen muss. Sollte der Datensatz so aussehen, wie der `dat_full` Datensatz?*

Antwort: Ja, der finale vorprozessierte Datensatz soll **von seiner Struktur her analog zu `dat_full`** aufgebaut sein.

Wichtig ist dabei die Unterscheidung zwischen **Struktur** und **konkreten Datenwerten**. Der Datensatz soll nicht dieselben Werte enthalten wie der ursprüngliche `dat_full`-Datensatz aus dem Semester. Das wäre auch nicht zu erwarten, weil du für die Abschlussabgabe mit deinen **individuell simulierten Rohdatensätzen** arbeitest. Diese simulierten Daten orientieren sich zwar an der Originalstudie, sind aber zufällig generierte Datensätze. Deshalb können sich konkrete Werte, Mittelwerte, Standardabweichungen, Signifikanzen und Effektstärken von den Originaldaten unterscheiden. Das ist kein Fehler, sondern eine erwartbare Eigenschaft der simulierten Daten.

Was aber gleich bzw. vergleichbar sein soll, ist die **Funktion des Datensatzes**. Wie im Seminar behandelt, soll aus den sieben Rohdatensätzen ein kombinierter, aufbereiteter und analysfähiger Gesamtdatensatz entstehen. Im Semester hast du diesen Schritt mit den Originaldaten durchgeführt, für die Abschlussabgabe machst du denselben grundlegenden Verarbeitungsschritt nun mit deinen simulierten Rohdaten.

Das bedeutet: Es geht nicht nur darum, die sieben Datensätze zusammenzuführen. Auch bei den simulierten Daten müssen die notwendigen Aufbereitungs- und Vorbereitungsschritte durchgeführt werden, damit der finale Datensatz für die Analysen verwendet werden kann. Dazu gehört bspw., dass benötigte Variablen gebildet werden (etwa Durchschnittswerte oder Skalenwerte), und dass Variablen bei Bedarf in den richtigen Wertebereich gebracht werden (z.B. durch eine Anpassung der Skalierung). Welche Punkte du bei der Datenaufbereitung insbesondere beachten sollst, ist in der [Checkliste](#) zur Abschlussarbeit beschrieben.

Frage: *Inwiefern sind die Annahmen und Voraussetzungen wie Varianzhomogenität tatsächlich relevant? Was ist die Konsequenz davon, wenn diese nicht gegeben sind?*

Antwort: Grundsätzlich sind Annahmen und Voraussetzungen statistischer Verfahren wichtig, weil sie beeinflussen, wie zuverlässig die Ergebnisse interpretiert werden können. Wie stark dieser Einfluss aber ist (und dementsprechend auch, welche Konsequenz eine Voraussetzungsverletzung hat), hängt von mehreren Komponenten ab, wie etwa dem Studiendesign, dem Analyseverfahren und der Stichprobengröße. Es gibt hier also leider keine pauschale Antwort.

Im Rahmen dieser Abschlussabgabe musst du die Voraussetzungen **nicht zwingend testen**. Du bist also frei zu entscheiden, ob du Voraussetzungstests durchführen möchtest

oder nicht. Wenn du dich entscheidest, die Voraussetzungen **nicht** zu testen, ist das für diese Abgabe in Ordnung.

Wenn du dich aber entscheidest, Voraussetzungen zu testen, muss dieses Vorgehen im **Datenanalyseplan** beschrieben sein. Zudem musst du dann auch entsprechend auf die Ergebnisse reagieren: Wenn eine Voraussetzung nicht erfüllt ist, sollte das nicht ignoriert werden, sondern im weiteren Vorgehen berücksichtigt werden, z.B. durch ein passendes alternatives Verfahren.

Frage: *Mir ist unklar, wie die Berechnung von Cohen's d bei der 2x3 Mixed ANOVA in R genau funktioniert.*

Antwort: Für die **2x3 Mixed ANOVA** wird Cohen's d nicht für die gesamte ANOVA als Ganzes berechnet. Für den allgemeinen ANOVA-Effekt verwendet man typischerweise Effektstärken wie η^2 oder partial η_p^2 .

Cohen's d wird hier nur für die **konkreten paarweisen Vergleiche** berechnet, also für die **post-hoc Tests**. Das bedeutet: Wenn du nach der Mixed ANOVA bestimmte Gruppen, Bedingungen oder Zeitpunkte miteinander vergleichst, kannst du für genau diese Vergleiche Cohen's d angeben.

Zuerst prüfst du also mit der 2x3 Mixed ANOVA, ob es insgesamt Hinweise auf Unterschiede gibt, z.B. einen Haupteffekt oder eine Interaktion. Wenn anschliessend relevante **post-hoc Vergleiche** durchgeführt werden, wird für diese einzelnen Vergleiche zusätzlich Cohen's d berechnet. Wie Berechnung von Cohen's d funktioniert hier gleich wie bei normalen t-Tests.